

TP5 : Traitement de données – Classification

Partie 1 : Les données « DataDiabet.xlsx » : 1h – 1h30 (max)

Reaven and Miller (1979) examined the relationship between measures of blood plasma glucose and insulin in 144 non-obese adult patients at the Stanford Clinical Research Center in order to examine ways of classifying people as "normal" (group=1), "overt diabetic" (group=2), or "chemical diabetic" (group=3).

Each patient underwent a glucose tolerance test. The variables are:

- relwt: relative weight, expressed as the ratio of actual weight to expected weight, given the person's height
- glufast: fasting plasma glucose level
- glutest: test plasma glucose level, a measure of glucose intolerance,
- insulin: plasma insulin during test, a measure of insulin response to oral glucose,
- steady: steady state plasma glucose, a measure of insulin resistance
- group: diagnostic group : 3 levels corresponding to 3 types of diabetes

Reaven, G. M. & Miller, R. G. (1979). An Attempt to Define the Nature of Chemical Diabetes Using a Multidimensional Analysis *Diabetologia*, **16**, 17-24.

Une des questions est de savoir si à partir de ces mesures il est possible de classer les groupes (types de diabètes). Pour répondre à cette question on se propose de réaliser une analyse discriminante.

1/ Charger et décrire les données

Attention : **penser bien à supprimer les individus inconnus** avant de réaliser les analyses univariée, bivariée et l'analyse discriminante. Les individus inconnus correspondent au group 4.

2/ Réaliser une analyse univariée des variables et commenter

- Boxplot de chaque variable en tenant compte des groupes
- Moyenne et Variance de chaque variable toujours en tenant compte des groupes

3/ Réaliser une analyse bivariée et commenter

4/ Réaliser l'analyse discriminante linéaire

5/ Classer les individus inconnus (donner soit la figure montrant les groupes dans l'espace des composantes discriminantes et les individus inconnus, soit la classe prédite pour chaque individu inconnu).

Partie 2 : Les données « occupancy »

Les données sont extraites d'un article et en partie modifiées pour le TP.

Luis M. Candanedo, Véronique Feldheim. (2016). Accurate occupancy detection of an office room from light, temperature, humidity and CO₂ measurements using statistical learning models, Energy and Buildings, 112, pp 28-39, ISSN 0378-7788, <https://doi.org/10.1016/j.enbuild.2015.11.071>.

Voici le descriptif des données et de leur recueil (extrait de l'article) :

This research has used data recorded from light, temperature, humidity and CO₂ sensors as a means to detect occupancy and a digital camera to establish ground occupancy for supervised classification model training. Combinations of these sensors can already be found in many buildings.

Data collection and setup

An office room with approximate dimensions of 5.85m × 3.50m × 3.53m (W × D × H) was monitored for the following variables: temperature, humidity, light and CO₂ levels.

An additional feature/variable is the humidity ratio. The humidity ratio in kgw/kgda was calculated using the measured temperature and relative humidity.

A microcontroller was employed to acquire the data. A ZigBee radio was connected to it and was used to transmit the information to a recording station. A digital camera was used to determine if the room was occupied or not. The camera time stamped pictures every minute and these were studied manually to label the data. See Fig. 1 for photograph of the setup.




Fig. 1. Data acquisition setup showing the light, CO₂, DHT22 (temperature/humidity) sensors, a ZigBee radio and a microcontroller card and the digital camera controlled by a Raspberry Pi.

Environmental conditions

The data was recorded during winter in Mons, Belgium during the month of February. The room was heated by hot water radiators that kept the room above 19°C. In order to estimate the difference in occupancy detection accuracy given by the models, they are tested for data sets when the office door is open and closed. The readings were recorded at time intervals of 14 s or 3 to 4 times per minute, and then averaged for the corresponding minute. The sensors were placed on a desk as shown in Fig. 2. The distance to the closest occupant was 1.1 m and to the second occupant about 2.9 m.




Fig. 2. (a) Room sketch showing the position of the sensors and the position of the occupants (b) Example of one of the pictures from the digital camera used to establish ground occupancy.

Les données sont enregistrées, extraites et mises en forme dans 2 fichiers excel.

Les variables sont extraites et mises en forme dans le fichier excel ; la 1^{ère} colonne correspond au numéro de l'échantillon temporel (données du 4 au 10 février 2015 dans le fichier training et données du 2 au 4 février). Les données correspondent aux enregistrements faits durant la journée (les données enregistrées la nuit ont été supprimées).

Une des questions est de savoir si à partir de ces mesures il est possible de détecter la présence ou non de personnes dans une pièce. Un tel système s'il permet cette détection pourrait être utilisées pour faire des statistiques sur le taux d'occupation des bâtiments. Après avoir répondu aux différentes questions vous devez **formuler une conclusion claire** sur la nécessité d'un ou de plusieurs capteurs pour pouvoir détecter la présence de personnes dans un bâtiment (quels capteurs, justifier leur choix, dans quel type de bâtiment, le domicile d'un particulier, des bureaux etc.)

1/ Vous utiliserez la base de données « training » pour toutes les 1^{ères} analyses (questions 1 à 6). Décrire le jeu de données et réaliser une analyse univariée et bivariée.

2/ Visualiser les données (training) sous la forme de courbes temporelles (ne passer pas trop de temps sur cette question).

```
plt.figure()
plt.plot(data['Temperature'])
```

3/ Effectuer une analyse discriminante (approche descriptive) de la base « training ».

4/ Effectuer également une analyse des différentes variables par des courbes ROC (toujours sur la base « training ») ; tracer également la courbe ROC de la composante discriminante.

5/ Choisir la « meilleure » variable et fixer un seuil sur cette variable pour la classification.

6/ Formulez votre conclusion

7/ Bonus : Réaliser alors une classification de la base de test en utilisant cette variable avec le seuil choisi et comparer la classe prédite à la classe vraie.

```
from sklearn.metrics import confusion_matrix
```